Comprendre le calcul de l'IPM pas à pas sur le recensement

Bases, colonnes, code du pipeline, et les trois variantes Emploi SU3, agriculture de subsistance et NEET approché

Pipeline `PythonIPM` — IPM Côte d'Ivoire

21 septembre 2026

Résumé

Cette note est le pendant, pour le **RGPH 2021**, de la note détaillée déjà produite sur l'EHCVM. Elle explique, sans supposer de connaissance préalable, comment les réponses du recensement deviennent des indicateurs de privation au niveau du ménage, quelle colonne de quelle base sert à chaque indicateur, ce que fait exactement chaque script du pipeline, puis comment sont calculés l'incidence H, l'intensité A et l'indice M_0. Elle détaille enfin les trois variantes demandées pour la dimension Emploi : **SU3 + agriculture de subsistance**, **SU3 uniquement** et **SU3 + NEET approché**. Les chiffres portent sur 5 616 487 ménages et 27 984 405 individus recensés, représentant 29,28 millions de personnes après application du taux net de couverture post-censitaire.

Table des matières

1 Ce qu'il faut retenir avant d'entrer dans le détail **3**

2 Données, unités et pondération de la population **3**
2.1 Les trois bases utilisées . . . 3
2.2 Trois clés de jointure différentes . . . 4
2.3 Ménage de construction, individu de comptage . . . 4
2.4 La grappe, pour les intervalles de confiance . . . 4

3 Des réponses brutes aux indicateurs de privation **4**
3.1 Les quatre indicateurs d'éducation . . . 5
3.2 L'unique indicateur de santé : la mortalité . . . 5
3.3 Les six indicateurs de conditions de vie . . . 6

4 Les indicateurs d'emploi, dans le détail **7**
4.1 Pourquoi SU3 est constructible sur le RGPH . . . 7
4.2 Chômage BIT ou SU1 . . . 7
4.3 SU3 : chômage plus main-d'œuvre potentielle . . . 7
4.4 Agriculture de subsistance : ce que mesure réellement le code . . . 8
4.5 NEET approché : en réalité un NEE . . . 8

5 Que fait chaque code du pipeline **8**
5.1 Vue d'ensemble . . . 9
5.2 `orchestrateur.py` — le socle et le chef d'orchestre . . . 9
5.3 `01_rgph_preconstruction_matrice_situationnelle.py` . . . 9
5.4 `02_construction_matrice_situationnelle.py` — où sont écrites les règles . . . 10
5.5 `03_matrice_privations_ponderees.py` . . . 10

5.6 `04_matrice_privations_censuree.py` 10
5.7 `05_indices_ipm.py` — les variantes 10
5.8 `06_validation_afmpi.py` 11
5.9 Comment lancer 11

6 Ce qui a été modifié pour rendre les variantes possibles sur le RGPH 11

7 Pondérations : comment chaque privation entre dans le score 12
7.1 IPM national de référence 12
7.2 Poids dans les trois variantes demandées 12

8 Du score du ménage à la pauvreté multidimensionnelle 12
8.1 Score pondéré, seuil, censure 12
8.2 H, A et M0 13

9 Exemple entièrement calculé pour un ménage fictif 13

10 Résultats nationaux des variantes 13
10.1 Pourquoi SU3 + agriculture augmente l'IPM de 16 % 14
10.2 Pourquoi SU3 uniquement fait fortement baisser l'IPM 14
10.3 Pourquoi SU3 + NEE donne un résultat intermédiaire 14

11 Lecture par milieu de résidence 14

12 Contribution des indicateurs à M0 15

13 Tableau de contrôle de l'IPM national de référence 15

14 Forces, limites et risques d'interprétation 16

15 Recommandation 16

16 Contrôles réalisés pour sécuriser les chiffres 17

1 Ce qu'il faut retenir avant d'entrer dans le détail

Le calcul est strictement le même que sur l'enquête — c'est la méthode Alkire–Foster — et il procède en quatre opérations :

1. les réponses individuelles et celles du logement sont ramenées au niveau du ménage ;
2. chaque situation devient un indicateur binaire : 1 si le ménage est privé, 0 sinon ;
3. les indicateurs sont pondérés, puis additionnés pour obtenir un score entre 0 et 1 ;
4. le ménage est pauvre si son score atteint au moins un tiers, soit $k = 1/3$.

$$\boxed{M_0 = H \times A}$$

Ce qui change par rapport à l'EHCVM, ce n'est donc pas la méthode, c'est **ce que la source sait mesurer**. Le recensement ne pose aucune question de santé, ne demande ni les années d'études ni le nombre de pièces, mais il recense les décès et il porte un **statut d'activité déjà construit par l'INS** qui contient la main-d'œuvre potentielle. C'est ce dernier point qui rend les variantes Emploi possibles sur le recensement.

Résultat central

Sur le RGPH, la variante **SU3 + agriculture de subsistance** donne $H = 43{,}1\ \%$, $A = 0{,}4464$ et $M_0 = 0{,}1924$, contre 0,1664 pour l'IPM national de référence. C'est la plus défendable des trois. **SU3 uniquement** fait tomber M_0 à 0,1380 et **SU3 + NEET approché** à 0,1522, mais dans les deux cas parce que l'on *retire* la privation agricole, qui est de loin la plus contributive du recensement, et non parce que SU3 serait moins sévère.

Ne jamais comparer l'IPM RGPH à l'IPM EHCVM

Les deux indices n'ont pas les mêmes indicateurs : l'IPM national du recensement vaut 0,1664, celui de l'enquête 0,2863. L'écart ne mesure rien de réel. La seule comparaison légitime passe par la variante *harmonisée*, bâtie sur le socle d'indicateurs commun aux deux sources.

2 Données, unités et pondération de la population

2.1 Les trois bases utilisées

L'extrait RGPH 2021 mis à disposition est réparti sur trois fichiers Stata. Le point à connaître avant de lire le code est que les variables de logement et de biens figurent dans *deux* fichiers, mais ne sont complètes que dans un seul.

Fichier	Lignes	Rôle dans l'IPM
`IPM_Data_191125.dta`	27 984 405 individus	démographie, éducation, emploi, état civil, géographie, pondération, taille du ménage. Il porte aussi le logement et les biens, mais renseignés pour un tiers des ménages seulement : **ils ne sont pas lus ici**
`IPM_Data_110924_men.dta`	5 528 535 ménages	logement, eau, éclairage, cuisson, sanitaires, biens d'équipement — complets. Une ligne par chef de ménage
`MORTALITE_RP2021_TRAITEMENT.dta`	269 901 décès	décès survenus dans les 12 mois précédant le recensement, dont l'âge au décès

Après agrégation, la table de travail compte **5 616 487 ménages**.

2.2 Trois clés de jointure différentes

C'est une particularité du RGPH, et une source d'erreur si on l'ignore :

Individus → ménage.
La colonne `ID_Menage` (renommée `id_menage`) identifie le ménage. C'est la clé de l'IPM RGPH.

Ménage → fichier logement.
Le fichier ménages n'est pas indexé par `ID_Menage` mais par `INDIV_ID`, l'identifiant *de l'individu chef de ménage*. La jointure passe donc par la ligne du chef repérée dans le fichier individus (`P16` = 1). 87 952 ménages n'ont pas de ligne correspondante : ils sont comptés non privés par convention sur les indicateurs de conditions de vie.

Ménage → fichier décès.
Le fichier des décès ne porte *ni* `INDIV_ID` *ni* `ID_Menage`. Le seul lien possible est la clé géographique complète en douze champs : `REGION`, `DEPART`, `SOUSPREFID`, `P_ZC`, `P04`, `P05`, `P06`, `P07`, `P09`, `P09A`, `P09B`, `P10`.

2.3 Ménage de construction, individu de comptage

La privation est construite au niveau du **ménage**, mais les résultats nationaux portent sur les **personnes**. Le poids de population du ménage i est :

$$n_i = \underbrace{\texttt{EW}_i}_{\text{taux net de couverture post-censitaire}} \times \texttt{TAILLE_MENAGE}_i .$$

Le recensement dénombre l'ensemble de la population ; `EW` ne corrige pas un plan de sondage mais la couverture incomplète du dénombrement, mesurée par l'enquête post-censitaire. La somme $\sum_i n_i$ vaut 29,28 millions de personnes.

Ne pas confondre deux pourcentages

L'agriculture de subsistance concerne 39,8 % des *ménages* recensés, mais 46,0 % de la *population* pondérée : les ménages agricoles sont plus grands que la moyenne. Les indices H, A et M_0 utilisent toujours la pondération population.

2.4 La grappe, pour les intervalles de confiance

Le recensement n'a pas de grappe d'échantillonnage. Pour calculer des erreurs-types, le pipeline reconstruit une unité primaire à partir de la **zone de dénombrement**, l'unité de terrain du recensement :

$$\texttt{grappe} = \texttt{SOUSPREFID} \times 10^7 + \texttt{P_ZC} \times 10^4 + \texttt{P05}.$$

On obtient ainsi 28 329 zones, qui servent de strates au calcul de la variance.

3 Des réponses brutes aux indicateurs de privation

Pour chaque indicateur j, le pipeline construit :

$$g^0_{ij} = \begin{cases} 1 & \text{si le ménage } i \text{ est privé selon le seuil } z_j, \\ 0 & \text{sinon.} \end{cases}$$

Un ménage sans personne appartenant à la tranche d'âge d'un indicateur est classé non privé sur cet indicateur. Ainsi, les 12,6 % de ménages sans membre de 17 à 40 ans ne sont jamais privés

au titre de SU3, et les 45,7 % de ménages sans jeune de 15 à 24 ans ne le sont jamais au titre du NEET.

3.1 Les quatre indicateurs d'éducation

Fréquentation scolaire.
Colonne `P30A`. Privé si au moins un enfant de 6 à 16 ans ne fréquente pas actuellement l'école, c'est-à-dire si `P30A` $\neq 1$ (les modalités 2 « a déjà fréquenté », 3 « jamais » et 8 « ne sait pas » sont toutes des privations). Privation : 21,7 % des ménages, **35,6 % de la population**.

Année de scolarité.
Colonne `P32`, diplôme le plus élevé. **Écart assumé :** le recensement ne demande ni le nombre d'années d'études ni la classe atteinte. Les dix années accomplies de l'énoncé national sont approchées par « au moins le BEPC », soit les codes 4 à 22. Le CEPE (code 2, six années) et le CQP (code 3) restent donc sous le seuil. Privé si aucun membre de 17 à 95 ans n'atteint ce niveau. Privation : 65,5 % des ménages, 63,2 % de la population.

Alphabétisation.
Colonnes `P29A` (sait lire et écrire une langue) et `P29_BA` (le français). Est alphabétisé celui pour qui `P29A` $= 1$ *et* `P29_BA` $= 1$. Privé si au moins un membre de 17 à 49 ans ne l'est pas. Privation : 58,9 % des ménages, **70,4 % de la population**.

État civil.
Colonne `P20`. Seule la modalité 1 « déclaré avec extrait d'acte » est non privée : la question de l'EHCVM porte sur la *possession* de l'acte, donc « déclaré sans acte » (2) est une privation. Privé si au moins un enfant de 5 à 15 ans est dans ce cas. Privation : 9,8 % des ménages, 15,2 % de la population.

Deux écarts au dofile officiel du RGPH 2021, assumés et documentés

Sur l'alphabétisation, le dofile officiel lit « aucun membre alphabétisé » (33,2 % des ménages) là où l'énoncé national dit « un membre ne sait pas lire ou écrire » (70,4 %). C'est l'énoncé littéral qui est retenu, comme dans l'EHCVM, pour que les deux sources ne divergent pas. Sur l'état civil, le dofile officiel ne compte privés que les codes 3 et 8 (9,7 % des ménages) : le pipeline y ajoute le code 2, soit 15,2 %.

3.2 L'unique indicateur de santé : la mortalité

Mortalité dans le ménage.
Fichier des décès, colonne `M61A2_AGE` (âge au décès, 998 = ne sait pas). Privé si au moins un enfant de moins de 18 ans est décédé dans le ménage. Privation : 0,7 % des ménages, 1,1 % de la population.

Cet indicateur remplace à lui seul les trois indicateurs de santé de l'EHCVM — assurance maladie, insécurité alimentaire et renoncement aux soins — qu'aucune question du recensement ne permet de reconstruire. Il porte donc **à lui seul le poids de 0,25** de la dimension.

La fenêtre de mortalité n'est pas celle de l'IPM mondial

Le RGPH recense les décès des **12 derniers mois** ; l'IPM mondial retient une fenêtre de **5 ans**. La privation est donc mécaniquement beaucoup plus rare ici, et les deux ne se comparent pas. Conséquence directe sur l'indice : avec un poids nominal de 25 % mais un taux de privation de 1,1 %, la dimension Santé ne contribue qu'à 1,6 % de M_0. Le poids de 0,25 est donc, en pratique, largement inemployé — et c'est ce qui rend l'IPM RGPH si sensible au choix des indicateurs d'emploi.

3.3 Les six indicateurs de conditions de vie

Tous lus dans le fichier ménages. Les matériaux adéquats sont définis *par exclusion*, comme dans le dofile officiel du RGPH : tout ce qui n'est pas dans la liste courte est rudimentaire.

Électricité.
Colonne `P51`. Privé si l'éclairage principal n'est ni le réseau, ni un groupe électrogène, ni le solaire. Population privée : 11,5 %.

Logement.
Colonnes `P45` (murs), `P46` (toit), `P47` (sol). Privé si l'un au moins des trois est rudimentaire. Sont adéquats : sol ciment, carreau ou moquette ; toit tôle, béton ou tuile ; murs semi-dur, géobéton ou dur. Le sol en bois et le mur en tôle sont comptés rudimentaires, conformément à la classification DHS. Population privée : 25,0 %.

Eau potable.
Colonne `P49`. Privé si la source n'est pas améliorée au sens des ODD. **Écart assumé :** le temps de trajet jusqu'au point d'eau n'est pas demandé au recensement, seul le premier critère du PNUD s'applique — l'indicateur est donc moins sévère que son homologue EHCVM. Population privée : 14,3 %.

Énergie de cuisson.
Colonne `P52`. Privé si le combustible n'est ni le gaz ni l'électricité. Population privée : 62,7 %.

Toilettes.
Colonne `P48`. Privé si les sanitaires ne sont pas améliorés. **Écart assumé :** le partage des sanitaires avec d'autres ménages n'est pas demandé. Population privée : 45,1 %.

Biens d'équipement.
Colonnes `P55AA` à `P57EE`. Privé si le ménage possède au plus un bien parmi radio, télévision, téléphone (fixe ou mobile), ordinateur, charrette, vélo, moto et réfrigérateur, et ne possède pas de voiture (`P55CC`). **Ici le recensement est plus complet que l'enquête :** les 8 biens de la définition PNUD y sont tous, charrette (« véhicule à traction animale ») comprise, alors que l'EHCVM n'en a que 7. Population privée : 18,2 %.

Ce que le recensement ne sait pas mesurer

Quatre indicateurs de l'EHCVM disparaissent : assurance maladie, insécurité alimentaire, renoncement aux soins (aucune question de santé) et promiscuité (le nombre de pièces n'est pas collecté). L'IPM national du RGPH compte donc **13 indicateurs** contre 16 dans l'enquête, et sa dimension Santé n'a plus qu'un seul indicateur.

4 Les indicateurs d'emploi, dans le détail

C'est la section qui justifie cette note : les trois variantes demandées ne pouvaient, jusqu'à présent, être calculées que sur l'EHCVM. Elles le sont désormais aussi sur le recensement.

4.1 Pourquoi SU3 est constructible sur le RGPH

L'EHCVM permet de reconstruire la main-d'œuvre potentielle à la main, à partir de la recherche d'emploi, de la disponibilité et du désir de travailler (questions 4.13 à 4.18). Le recensement ne pose pas ces questions dans le même détail — et c'est ce qui avait fait écarter les variantes Emploi côté RGPH.

Mais le recensement porte une variable **déjà construite par l'INS**, `Statut_OQPtbb`, qui code directement le statut d'activité en quatre modalités :

Code	Statut	Individus	Part
0	Occupé	11 082 635	39,6 %
1	Chômeur au sens du BIT	403 834	1,4 %
2	Inactif	13 794 677	49,3 %
3	**Main-d'œuvre potentielle**	**2 127 898**	**7,6 %**
—	Non renseigné (hors champ d'âge)	575 361	2,1 %
	Total	27 984 405	100,0 %

La modalité 3 *est* la main-d'œuvre potentielle. SU3 se lit donc directement :

$$\text{SU3} = \{\texttt{Statut_OQPtbb} \in \{1,\, 3\}\} = \text{chômage BIT} \;\cup\; \text{main-d'œuvre potentielle}.$$

Le point méthodologique de cette note

SU3 n'est pas *approché* sur le RGPH : il est **lu** dans une variable officielle de l'INS, là où l'EHCVM doit le reconstruire. Le recensement est, sur ce point précis, la source la plus directe des deux.

Le choix de `Statut_OQPtbb` plutôt que de `Statut_OQPtb`, l'autre variable de statut présente dans la base, n'est pas anodin : `Statut_OQPtb` donne 21,6 % de ménages privés au chômage contre 5,9 % ici, parce qu'elle n'intègre pas le reclassement INS des personnes déclarées sans activité mais en réalité occupées. `Statut_OQPtbb` a par ailleurs été vérifiée contre la construction du dofile officiel du RGPH 2021, qui applique les trois critères BIT explicitement : les deux ne diffèrent que sur 18 910 individus sur 28 millions, soit 0,07 %.

4.2 Chômage BIT ou SU1

Privé si au moins un membre de 17 à 40 ans a `Statut_OQPtbb` = 1. On compte 298 644 chômeurs dans cette tranche sur 11,4 millions de personnes concernées, soit **2,6 %**. Au niveau du ménage : 196 019 ménages privés, 3,5 % des ménages et **5,9 % de la population**.

Le chômage BIT est rare, pour les mêmes raisons que dans l'enquête : une heure de travail suffit à être classé occupé, et les personnes découragées qui ne recherchent plus activement sortent du chômage.

4.3 SU3 : chômage plus main-d'œuvre potentielle

Privé si au moins un membre de 17 à 40 ans a `Statut_OQPtbb` $\in \{1, 3\}$. On compte 1 661 331 personnes, soit **14,6 %** des 17–40 ans — cinq fois et demie le chômage BIT. Au niveau du ménage : 1 033 121 ménages, 18,4 % des ménages et **26,3 % de la population**.

Tout chômeur BIT appartient nécessairement à SU3. La propriété a été vérifiée dans les données : **aucun** des 196 019 ménages privés au titre du chômage ne se trouve hors de SU3.

Pourquoi il ne faut pas additionner mécaniquement SU1 et SU3

SU3 contient déjà SU1. Une variante « SU1 + SU3 » attribue donc deux privations au même chômage. Ce montage peut être calculé comme test (option `--su1_su3`), mais il n'est pas recommandé comme spécification principale.

4.4 Agriculture de subsistance : ce que mesure réellement le code

Colonnes `Statut_OQPtbb`, `P36BNEWtb` (branche d'activité, nomenclature NAEMA) et `P37NEWtb` (situation dans la profession). Le chef de ménage est compté en subsistance s'il est simultanément :

- **occupé** : `Statut_OQPtbb` $= 0$;
- dans une **branche agricole** : `P36BNEWtb` dans l'intervalle [01000 ; 04000[, soit les divisions NAEMA 01 à 03 (agriculture, sylviculture, pêche) ;
- **à son compte ou comme aide familial** : `P37NEWtb` $\in \{3, 5\}$, ce qui exclut le salariat, l'apprentissage et le statut d'employeur.

Le ménage n'est privé que si c'est le **chef** qui est dans ce cas (`P16` $= 1$). Cette règle donne 2 234 464 ménages privés, soit 39,8 % des ménages et **46,0 % de la population**.

Une approximation différente de celle de l'EHCVM

L'EHCVM observe le travail *exclusif sur son propre champ* ; le RGPH ne pose pas cette question et observe la *branche* croisée avec le *statut non salarié*. Les deux approximations visent la même réalité mais ne coïncident pas : la version RGPH inclut la pêche et la sylviculture, et n'exclut pas un chef qui ferait aussi du commerce. Dans les deux cas, la destination de la production — le vrai critère OIT de la subsistance — n'est pas observée. Le libellé prudent reste : « chef de ménage dépendant d'une activité agricole non salariée — proxy de l'agriculture de subsistance ».

4.5 NEET approché : en réalité un NEE

L'indicateur international NEET porte sur les jeunes de 15 à 24 ans qui ne sont ni en emploi, ni en éducation, ni en formation. Le recensement observe les deux premiers termes, pas le troisième. Le pipeline construit donc, sur les colonnes `Statut_OQPtbb` et `P30A` :

$$\text{NEE approché} = (15\text{–}24 \text{ ans}) \cap (\texttt{Statut_OQPtbb} \neq 0) \cap (\texttt{P30A} \neq 1).$$

On obtient 1 692 665 jeunes sur 5 920 170, soit **28,6 %**. Au niveau du ménage : 1 105 964 ménages, 19,7 % des ménages et **30,9 % de la population**. Comme dans l'EHCVM, le chiffre est une **borne supérieure** du NEET : des jeunes comptés NEE peuvent suivre une formation non observée. L'indicateur garde le nom `neet_approx` précisément pour que cette limite ne se perde pas en route.

SU3 et NEE se recouvrent dans 473 999 ménages, soit 14,2 % de la population. Le couple SU3 + NEE mesure deux objets différents, mais donne deux fois du poids à certains épisodes de non-emploi des jeunes.

5 Que fait chaque code du pipeline

Le pipeline tourne sur **deux sources** avec le même enchaînement d'étapes. La source est portée par la variable d'environnement `IPM_SOURCE` (`ehcvm` ou `rgph`) ; elle détermine le dossier de

données, la clé du ménage, les désagrégations disponibles et le *suffixe* de tous les fichiers produits. Les sorties des deux sources cohabitent donc sans se marcher dessus.

5.1 Vue d'ensemble

Script	Entrée	Sortie
`orchestrateur.py`	—	socle commun (chemins, clés, journaux) *et* chef d'orchestre
`01_rgph_preconstruction_matrice_situationnelle.py`	les 3 bases `.dta` du recensement	`preconstruction_matrice_situationnelle_rgph2021.dta`
`02_construction_matrice_situationnelle.py`	la préconstruction	`matrice_situationnelle_rgph2021.dta` + le vecteur z
`03_matrice_privations_ponderees.py`	la matrice g^0	poids w, matrice pondérée, score c_i
`04_matrice_privations_censuree.py`	la matrice pondérée	matrice censurée, statuts au seuil k
`05_indices_ipm.py`	la matrice g^0 + le vecteur z	H, A, M_0, contributions, désagrégations, classeurs `.xlsx`
`06_validation_afmpi.py`	les sorties de 05	contrôle croisé par un package indépendant

5.2 `orchestrateur.py` — le socle et le chef d'orchestre

Ce module a deux rôles. Comme **socle**, il porte ce qui est commun à toutes les étapes : les chemins du projet, la clé de fusion (`id_menage` pour le RGPH, `grappe + menage + vague` pour l'EHCVM), les colonnes techniques transportées d'une étape à l'autre, la journalisation, et deux listes décisives :

`SOCLE_COMMUN`
: les indicateurs que l'EHCVM *et* le RGPH savent mesurer. Il sert à la variante harmonisée, seule comparable en niveau d'une source à l'autre.

`HORS_IPM_NATIONAL`
: les indicateurs produits par l'étape 02 mais volontairement *exclus* de l'indice publié : `chomage_su3` et `neet_approx`. Ils existent dans la matrice de privation et dans le vecteur z, et seules les variantes qui les nomment les emploient. C'est ce mécanisme qui garantit que l'ajout de SU3 et du NEET au recensement **n'a pas modifié d'un millième** l'IPM national : il vaut 0,1664 avant comme après.

Comme **chef d'orchestre**, il enchaîne les étapes en sous-processus — une étape qui échoue arrête la chaîne — et écrit un journal d'ensemble. Il porte aussi une fonction `compacter` qui ramène chaque colonne entière au plus petit type qui la contient : sur 5,6 millions de lignes, stocker un indicateur 0/1 en `int64` octuple la taille des fichiers de travail. Les vrais flottants (scores c_i, pondérations) restent en `float64`, car ils sont comparés d'une étape à l'autre à 10^{-9} près.

5.3 `01_rgph_preconstruction_matrice_situationnelle.py`

C'est le seul script réellement spécifique au recensement. Son contrat de sortie : **une ligne par ménage, et pour chaque indicateur l'effectif *concerné* à côté de l'effectif *défavorable*** — sans qu'aucun seuil ne soit appliqué à ce stade. Il procède en cinq temps :

1. **Parcours du fichier individus par morceaux de 3 millions de lignes.** 28 millions de lignes ne tiennent pas en mémoire. Chaque morceau est agrégé séparément par ménage, puis les agrégats sont resommés : un ménage coupé entre deux morceaux est correctement reconstitué, puisque la somme d'une somme reste une somme. Les lignes de chef sont mises de côté au passage, car elles portent la géographie, la pondération et la taille du ménage.

2. **Situations individuelles** (fonction `situations_individuelles`). Chaque colonne est un booléen, et l'appartenance à la tranche d'âge concernée est portée par une colonne *séparée* — c'est elle qui permettra à l'étape 02 de distinguer « non privé » de « non concerné ». Un âge « ne sait pas » (code 999) ne fait entrer dans aucune tranche. **C'est ici qu'ont été ajoutées** les colonnes `chomeurs_su3_17_40`, `jeunes_15_24` et `jeunes_neet_approx_15_24`.
3. **Conditions de vie et biens** (fichier ménages), avec le comptage des 8 biens PNUD.
4. **Mortalité juvénile** (fichier des décès), jointe par la clé géographique en douze champs.
5. **Assemblage et contrôles** : unicité de la clé, pondérations strictement positives, distributions, valeurs manquantes.

5.4 `02_construction_matrice_situationnelle.py` — où sont écrites les règles

À partir de cette étape, le code est **commun aux deux sources** : il ne travaille plus que sur des colonnes de situation normalisées. Ce qui change d'une source à l'autre, ce sont les énoncés et les seuils, rassemblés dans une carte officielle des indicateurs. Chaque entrée déclare :

`colonne`
: le nom produit dans X (1 = privé, 0 = non privé) ;

`regle`
: le seuil appliqué, écrit comme une fonction ;

`situation`
: les colonnes de la préconstruction qui portent la situation brute ;

`eligibilite`
: la colonne qui dit combien de membres sont concernés.

Chaque indicateur suit soit la *proposition nationale*, soit l'*application du PNUD*, et l'étiquette est portée dans la carte. Le script produit aussi le **vecteur** z, la liste des indicateurs avec leur dimension et leur valeur de coupure : c'est lui que lira l'étape 05 pour construire les poids, ce qui garantit que w et z portent toujours sur exactement les mêmes colonnes.

C'est ici qu'ont été ajoutés les deux indicateurs `chomage_su3` et `neet_approx` à la liste du RGPH, qui passe de 13 à 15 indicateurs — dont 13 seulement entrent dans l'IPM national.

5.5 `03_matrice_privations_ponderees.py`

Calcule le vecteur de poids w : les dimensions sont équipondérées, et à l'intérieur d'une dimension le poids est partagé également entre les indicateurs. Puis la matrice pondérée $w_j g^0_{ij}$ et le score c_i. **C'est ce script qui retire `HORS_IPM_NATIONAL`** du vecteur z avant de calculer les poids : la chaîne 03–04 ne voit donc jamais SU3 ni le NEET, et l'IPM national reste celui qui est publié.

5.6 `04_matrice_privations_censuree.py`

Applique le seuil $k = 1/3$ et remet à zéro les privations des ménages *non* pauvres. C'est la censure Alkire–Foster, qui rend M_0 décomposable par indicateur. Le script calcule aussi les deux statuts complémentaires : vulnérable ($0{,}20 \le c_i < 1/3$) et pauvreté sévère ($c_i \ge 0{,}50$).

5.7 `05_indices_ipm.py` — les variantes

Le script principal. Il repart de la matrice g^0 brute et **refait** la pondération et la censure pour chaque variante, puisque les poids changent d'une variante à l'autre. Trois variantes sont toujours calculées :

IPM national
4 dimensions, tous les indicateurs sauf `HORS_IPM_NATIONAL` ;

IPM international
3 dimensions, sans l'Emploi ;

IPM harmonisé
le socle commun EHCVM/RGPH, seule variante comparable entre sources.

La variante nationale est comparée par `assert` à la matrice censurée de l'étape 04 : si les deux chemins de calcul divergeaient d'un millième, le script s'arrêterait. C'est ce contrôle qui garantit qu'aucune modification du code ne déplace silencieusement l'indice publié.

À ces trois variantes s'ajoutent, **sur option**, les variantes Emploi. Chacune est définie par la liste des indicateurs qu'elle *exclut* :

Option	Emploi retenu	Exclusions déclarées
`--su1_su3`	chômage, SU3, subsistance	`neet_approx`
`--su3`	SU3, subsistance	`chomage`, `neet_approx`
`--su3_seul`	SU3	`chomage`, `neet_approx`, `emploi_subsistance`
`--su3_neet`	SU3, NEET approché	`chomage`, `emploi_subsistance`

Les exclusions sont *explicites* plutôt qu'implicites, afin qu'un indicateur expérimental ne puisse pas contaminer une variante par oubli. Le script produit ensuite, pour chaque variante, les indices désagrégés par milieu, région, département, sous-préfecture et taille du ménage, avec intervalles de confiance à 95 % et coefficient de variation, puis les contributions de chaque indicateur à M_0, et enfin un classeur Excel de restitution.

5.8 `06_validation_afmpi.py`

Hors chaîne. Recalcule H, A, M_0 et les contributions avec le package indépendant `afmpi`, et compare à 10^{-6} près. C'est un contrôle croisé : deux implémentations différentes de la même méthode doivent donner le même nombre.

5.9 Comment lancer

Commande	Effet
`python pipeline/orchestrateur.py`	les deux sources, tout le pipeline
`python pipeline/orchestrateur.py --source rgph`	le recensement seul
`python pipeline/orchestrateur.py --check`	les auto-contrôles de chaque étape
`python pipeline/orchestrateur.py --su3 --su3_seul --su3_neet`	ajoute les trois variantes Emploi, sur les deux sources

6 Ce qui a été modifié pour rendre les variantes possibles sur le RGPH

Quatre fichiers, aucune modification de la méthode de calcul :

Étape 01 RGPH — `01_rgph_preconstruction_...py`
ajout de la tranche d'âge NEET (15–24 ans), de la constante `SOUS_UTILISATION_SU3` $= \{1, 3\}$, et des trois colonnes de situation `chomeurs_su3_17_40`, `jeunes_15_24` et `jeunes_neet_approx_15_24`. Les auto-contrôles unitaires ont été étendus en conséquence : un inactif n'entre ni dans SU1 ni dans SU3, une personne de la main-d'œuvre potentielle entre dans SU3 mais pas dans SU1, un jeune scolarisé n'est pas NEET.

Étape 02 — `02_construction_matrice_...py`
ajout des deux indicateurs `chomage_su3` et `neet_approx` à la carte du RGPH, avec leurs énoncés propres au recensement. La source passe de 13 à 15 indicateurs produits.

`orchestrateur.py`
suppression du filtre qui retirait les options Emploi du passage sur le recensement. Les quatre options valent désormais pour les deux sources.

`05_indices_ipm.py`
suppression du garde-fou `assert SOURCE == "ehcvm"` qui interdisait les variantes Emploi au RGPH.

L'IPM national n'a pas bougé

`chomage_su3` et `neet_approx` figurent dans `HORS_IPM_NATIONAL` : l'étape 03 les retire du vecteur z et la variante nationale de l'étape 05 les exclut explicitement. Après recalcul complet, l'IPM national du RGPH vaut toujours $H = 38{,}8\ \%$, $A = 0{,}4287$ et $M_0 = 0{,}1664$, identiques aux valeurs publiées dans la note de lecture des sorties.

7 Pondérations : comment chaque privation entre dans le score

Les quatre dimensions sont équipondérées : chacune reçoit 0,25. À l'intérieur d'une dimension, ce poids est partagé également entre les indicateurs retenus.

7.1 IPM national de référence

Dimension	Nombre d'indicateurs	Poids par indicateur	Poids total
Éducation	4	0,0625	0,25
Santé	1	0,2500	0,25
Emploi	2	0,1250	0,25
Conditions de vie	6	0,041667	0,25
Total	13	—	1,00

Le contraste avec l'EHCVM est frappant : là où l'enquête partage les 0,25 de la Santé entre trois indicateurs, le recensement les concentre sur la seule mortalité.

7.2 Poids dans les trois variantes demandées

Variante	Indicateurs d'emploi retenus	Poids
SU3 + agriculture	SU3 ; chef en activité agricole non salariée	0,125 chacun
SU3 uniquement	SU3	0,250
SU3 + NEET approché	SU3 ; NEE des 15–24 ans	0,125 chacun

Les poids des trois autres dimensions ne changent jamais. Seul le partage des 0,25 de la dimension Emploi varie.

8 Du score du ménage à la pauvreté multidimensionnelle

8.1 Score pondéré, seuil, censure

Pour le ménage i :

$$c_i = \sum_{j=1}^{J} w_j g_{ij}^0, \qquad \rho_i(k) = \mathbf{1}(c_i \geq 1/3), \qquad g_{ij}^0(k) = g_{ij}^0 \, \rho_i(k).$$

Un score de 0,40 signifie que le ménage subit 40 % de l'ensemble pondéré des privations possibles. Il ne signifie pas que 40 % des membres du ménage sont privés. Un score exactement égal à un tiers est pauvre.

8.2 H, A et M0

Soit n_i le poids de population du ménage et $q_i = \rho_i(k)$ son statut de pauvreté :

$$H = \frac{\sum_i n_i q_i}{\sum_i n_i}, \qquad A = \frac{\sum_i n_i c_i q_i}{\sum_i n_i q_i}, \qquad M_0 = HA = \frac{\sum_i n_i c_i q_i}{\sum_i n_i}.$$

M0 n'est pas un pourcentage ordinaire

Un M_0 de 0,1924 ne signifie pas que 19,24 % des personnes sont pauvres. Dans la variante SU3 + agriculture, 43,1 % sont pauvres et leur intensité moyenne est de 44,64 %. Le produit $0{,}4311 \times 0{,}4464$ donne 0,1924.

9 Exemple entièrement calculé pour un ménage fictif

Considérons la variante SU3 + agriculture sur le RGPH. Supposons un ménage privé sur six indicateurs : année de scolarité, alphabétisation, SU3, agriculture, énergie de cuisson et toilettes — mais *sans* décès d'enfant.

Indicateur privé	g_{ij}^0	w_j	$w_j g_{ij}^0$
Année de scolarité	1	0,062500	0,062500
Alphabétisation	1	0,062500	0,062500
SU3	1	0,125000	0,125000
Agriculture de subsistance	1	0,125000	0,125000
Énergie de cuisson	1	0,041667	0,041667
Toilettes	1	0,041667	0,041667
Score c_i			**0,458334**

Comme $0{,}458334 \geq 1/3$, le ménage est pauvre. Dans la variante **SU3 uniquement**, la privation agricole disparaît et SU3 vaut 0,25 : le score devient $0{,}0625 + 0{,}0625 + 0{,}25 + 0{,}041667 + 0{,}041667 = 0{,}458334$, identique par coïncidence. Mais pour un ménage agricole *sans* SU3 — le cas le plus fréquent en milieu rural — le score perd 0,125 d'un coup et peut repasser sous le seuil. C'est tout le mécanisme de la baisse observée.

10 Résultats nationaux des variantes

Dimension Emploi	H	A	M_0	**Vulnér.**	**Sévère**
Référence : chômage BIT + agriculture	38,8 %	0,4287	0,1664	20,7 %	7,8 %
SU3 + agriculture de subsistance	43,1 %	0,4464	**0,1924**	20,8 %	12,3 %
SU3 uniquement	30,9 %	0,4473	**0,1380**	32,6 %	9,2 %
SU3 + NEET approché (NEE)	34,6 %	0,4401	**0,1522**	28,3 %	9,0 %

Les intervalles de confiance à 95 % de M_0 sont respectivement :

— référence : [0,1645 ; 0,1684] ;

— SU3 + agriculture : [0,1903 ; 0,1946] ;

— SU3 uniquement : [0,1366 ; 0,1395] ;

— SU3 + NEE : [0,1506 ; 0,1537].

Les intervalles sont environ dix fois plus étroits que ceux de l'EHCVM : c'est l'effet de l'exhaustivité du recensement. **Aucun des écarts entre variantes n'est imputable à l'imprécision statistique** — ils sont tous largement significatifs.

10.1 Pourquoi SU3 + agriculture augmente l'IPM de 16 %

SU3 remplace le chômage BIT au même poids de 0,125, mais la privation population passe de 5,9 % à 26,3 %, soit un quadruplement. De nombreux ménages auparavant juste sous un tiers franchissent le seuil : H passe de 38,8 % à 43,1 %. Chez les pauvres, SU3 ajoute aussi de la privation, ce qui porte A de 0,4287 à 0,4464. La pauvreté sévère, elle, augmente de moitié (7,8 % → 12,3 %).

10.2 Pourquoi SU3 uniquement fait fortement baisser l'IPM

SU3 reçoit 0,25, mais la privation agricole — qui concernait 46,0 % de la population, la plus fréquente des indicateurs d'emploi — disparaît. La hausse du poids de SU3 ne compense pas cette suppression, parce que les deux privations ne touchent pas les mêmes ménages : un chef agriculteur est *occupé*, donc hors SU3 par construction. Des ménages ruraux perdent 0,125 de score et repassent sous le seuil.

Le signe le plus net est le report vers la vulnérabilité : la part de vulnérables bondit de 20,7 % à 32,6 %. Ce ne sont pas des ménages qui vont mieux, ce sont les mêmes ménages passés juste sous la barre.

Une baisse de définition, pas une amélioration

Les ménages et la date sont identiques dans les quatre colonnes. Seule la définition de l'indice change. Une comparaison entre variantes n'est en aucun cas une évolution temporelle.

10.3 Pourquoi SU3 + NEE donne un résultat intermédiaire

Le NEE est plus fréquent que SU3 : 30,9 % de la population au niveau ménage contre 26,3 %. Il remplace donc une partie du pouvoir discriminant de l'agriculture, mais déplace la dimension vers la jeunesse et la déconnexion de l'école. La variante devient moins rurale et plus sensible aux ménages comprenant des jeunes de 15 à 24 ans. Elle ignore en revanche complètement les 45,7 % de ménages qui n'en comptent aucun.

11 Lecture par milieu de résidence

Le RGPH distingue trois milieux, là où l'EHCVM n'en code que deux.

	Urbain		Rural		Semi-urbain	
Variante	H	M_0	H	M_0	H	M_0
Référence	5,4 %	0,0212	71,1 %	0,3075	41,0 %	0,1705
SU3 + agriculture	8,9 %	0,0355	75,4 %	0,3425	48,3 %	0,2079
SU3 uniquement	17,1 %	0,0721	43,3 %	0,1977	35,6 %	0,1614
SU3 + NEE	15,1 %	0,0623	51,9 %	0,2323	43,1 %	0,1893

Part de population : urbain 44,8 %, rural 45,8 %, semi-urbain 9,4 %.

Le tableau est le résultat le plus important de cette note. Retirer l'agriculture **triple** l'IPM urbain (0,0212 → 0,0721) et **réduit d'un tiers** l'IPM rural (0,3075 → 0,1977). Le rapport rural/urbain passe de 14,5 à 2,7.

Conséquence directe sur le ciblage

Les variantes ne changent pas seulement le niveau national : elles changent *qui* est désigné comme pauvre. Une politique calibrée sur « SU3 uniquement » orienterait des moyens vers des zones urbaines que l'IPM de référence classe parmi les moins pauvres du pays. Le choix de variante est donc une décision de politique publique, pas un réglage technique.

12 Contribution des indicateurs à M0

La contribution de l'indicateur j s'écrit :

$$\text{Contribution}_j = \frac{w_j \, CH_j}{M_0},$$

où CH_j est le taux de privation censuré : la part de population à la fois pauvre et privée sur l'indicateur j. La somme des contributions vaut 100 %.

Contribution à M_0	**Référence**	**SU3+agri.**	**SU3 seul**	**SU3+NEE**
Chômage BIT	1,8 %	—	—	—
SU3	—	9,3 %	35,5 %	13,0 %
Agriculture de subsistance	26,8 %	24,5 %	—	—
NEET approché (NEE)	—	—	—	19,1 %
Dimension Emploi	**28,6 %**	**33,8 %**	**35,5 %**	**32,1 %**
Éducation	40,6 %	37,8 %	37,1 %	39,7 %
Conditions de vie	29,2 %	27,0 %	25,5 %	26,4 %
Santé	1,6 %	1,4 %	1,9 %	1,7 %

Deux enseignements. D'abord, l'agriculture de subsistance est, à elle seule, le **deuxième contributeur de l'IPM RGPH** après l'alphabétisation — la retirer ne peut pas être sans conséquence. Ensuite, la dimension Santé, dotée d'un poids nominal de 25 %, ne contribue qu'à 1,6 %. C'est ce déséquilibre qui amplifie mécaniquement le rôle de l'Emploi dans le recensement, et qui explique que les écarts entre variantes y soient bien plus marqués que dans l'enquête.

13 Tableau de contrôle de l'IPM national de référence

Le tableau relie règle, fréquence, poids et contribution. Le taux population est non censuré ; la contribution ne porte que sur les pauvres après censure.

Indicateur	**Dimension**	**Privation pop.**	w_j	**Contribution**
Fréquentation scolaire	Éducation	35,6 %	0,0625	8,7 %
Année de scolarité	Éducation	63,2 %	0,0625	13,4 %
Alphabétisation	Éducation	70,4 %	0,0625	13,6 %
État civil	Éducation	15,2 %	0,0625	4,9 %
Mortalité dans le ménage	Santé	1,1 %	0,2500	1,6 %
Chômage BIT	Emploi	5,9 %	0,1250	1,8 %
Agriculture de subsistance	Emploi	46,0 %	0,1250	26,8 %

Indicateur	Dimension	Privation pop.	w_j	Contribution
Électricité	Conditions de vie	11,5 %	0,0417	2,5 %
Logement	Conditions de vie	25,0 %	0,0417	4,7 %
Eau potable	Conditions de vie	14,3 %	0,0417	2,8 %
Énergie de cuisson	Conditions de vie	62,7 %	0,0417	9,5 %
Toilettes	Conditions de vie	45,1 %	0,0417	7,4 %
Biens d'équipement	Conditions de vie	18,2 %	0,0417	2,3 %
Total des contributions				100,0 %

Pour mémoire, les deux indicateurs hors IPM national : SU3 prive 26,3 % de la population et le NEET approché 30,9 %.

14 Forces, limites et risques d'interprétation

SU3 est mieux mesuré sur le RGPH que sur l'EHCVM.
Il est lu dans une variable officielle de l'INS plutôt que reconstruit. C'est le principal argument en faveur du recensement sur cette dimension précise.

SU3 est préférable au chômage BIT strict.
Il récupère le découragement et l'attachement incomplet au marché du travail : 14,6 % des 17–40 ans contre 2,6 %. Il reste toutefois limité à cette tranche d'âge.

L'agriculture mesure une vulnérabilité absente de SU3.
Un chef travaillant dans son champ est *occupé* et n'entre pas dans SU3. Sans indicateur de qualité de l'emploi, cette réalité — 46 % de la population — disparaît entièrement de la dimension.

Le proxy agricole du RGPH n'est pas celui de l'EHCVM.
Branche agricole croisée avec statut non salarié, contre travail exclusif sur son propre champ. Les deux visent la même chose, aucun n'observe la destination de la production.

SU3 seul donne un poids très fort à une privation unique.
Chaque ménage SU3 reçoit 0,25 d'un coup, tout en ignorant la qualité des emplois existants. Le report massif vers la vulnérabilité (32,6 %) en est le symptôme.

Le NEE n'est pas un NEET complet.
La formation en cours manque, le taux est donc une borne supérieure. L'indicateur ne concerne par ailleurs que les 54,3 % de ménages comprenant un jeune de 15 à 24 ans.

La dimension Santé est structurellement faible.
Un poids de 0,25 pour une contribution de 1,6 %. Toute conclusion tirée de l'IPM RGPH doit tenir compte de ce que la mortalité sur 12 mois ne peut pas porter, à elle seule, un quart de l'indice.

15 Recommandation

1. Retenir comme variante principale **SU3 + dépendance agricole non salariée du chef**, avec deux indicateurs de poids 0,125. C'est la seule qui couvre à la fois la sous-utilisation de la main-d'œuvre et la précarité de l'emploi existant.
2. Qualifier explicitement l'indicateur agricole de **proxy**, car la destination de la production n'est pas observée.
3. Conserver **SU3 uniquement** comme test de sensibilité, en documentant que la baisse de M_0 est un effet de suppression d'indicateur, pas une amélioration.

4. Conserver **SU3 + NEE** comme scénario exploratoire, sans l'appeler NEET dans une publication officielle tant que la formation en cours n'est pas mesurée.
5. Ne jamais présenter ces quatre chiffres côte à côte sans le tableau par milieu : c'est là que se joue la conséquence réelle du choix.
6. Au prochain recensement, ajouter une question sur la destination principale de la production agricole et une question sur la formation suivie actuellement.

16 Contrôles réalisés pour sécuriser les chiffres

— auto-contrôles unitaires des étapes 01, 02 et 05, étendus aux nouvelles colonnes : un inactif n'entre ni dans SU1 ni dans SU3 ; une personne de la main-d'œuvre potentielle entre dans SU3 mais pas dans SU1 ; un jeune scolarisé n'est pas NEET ; un âge « ne sait pas » n'entre dans aucune tranche ;

— contrôle que tout ménage privé au chômage BIT est également privé selon SU3 : 0 exception sur 196 019 ménages ;

— `assert` de l'étape 05 vérifiant que la variante nationale reproduit à l'identique la matrice censurée produite indépendamment par l'étape 04 ;

— contrôle que la somme des lignes censurées redonne exactement $c_i(k)$: écart maximal nul ;

— contrôle de décomposabilité : pour chaque variable de désagrégation, les M_0 de groupe pondérés par la part de population redonnent le M_0 national ;

— vérification que la somme des poids vaut 1 à 10^{-9} près dans chacune des six variantes ;

— vérification que l'IPM national du RGPH est inchangé après l'ajout de SU3 et du NEET : $H = 38{,}8\ \%$, $A = 0{,}4287$, $M_0 = 0{,}1664$, identiques aux valeurs publiées ;

— distribution complète de `Statut_OQPtbb` relue sur les 27 984 405 individus du fichier pour confirmer le codage des quatre modalités.

Conclusion

Les variantes Emploi sont désormais calculables sur le recensement, et SU3 y est même mieux mesuré que dans l'enquête puisqu'il est lu dans une variable officielle de l'INS. Le choix restant n'est pas informatique : il consiste à décider quelle conception de la privation d'emploi doit entrer dans l'IPM. Sur le RGPH, l'enjeu est plus lourd que sur l'EHCVM, parce que la dimension Santé y est presque muette et que l'Emploi y pèse d'autant plus. Les résultats conduisent à préférer SU3 accompagné de l'indicateur agricole, sous un libellé prudent.

Fichiers de résultats associés

— `indices_ipm_su3_rgph2021.xlsx` : SU3 + agriculture ;

— `indices_ipm_su3_seul_rgph2021.xlsx` : SU3 uniquement ;

— `indices_ipm_su3_neet_rgph2021.xlsx` : SU3 + NEE ;

— `contributions_ipm_su3*_rgph2021.csv` : contributions par indicateur ;

— chaque classeur contient les résultats nationaux, les contributions, les poids et les désagrégations par milieu, région, département, sous-préfecture et taille du ménage.